

Actividad #3: Servicio Web de Detección de Enfermedades Foliares en Café

Arquitectura de Computación en la Nube con Visión por Computadora e IA Generativa

Estudiante: Nirrol Garcia Asignatura: Computación en la Nube Fecha: Agosto 2026

1. Resumen Ejecutivo y Objetivos

El presente proyecto aborda el desarrollo e implementación de un servicio web en la nube diseñado para el diagnóstico fitosanitario de hojas de café (*Coffea arabica*). A través de un enfoque híbrido que combina inteligencia artificial convolucional (Visión por Computadora) y un Modelo de Lenguaje de Gran Escala (LLM a través de la API de Groq), la plataforma permite detectar patologías como Roya y Cercospora, generando simultáneamente planes de tratamiento y manejo agronómico preventivo en tiempo real.

2. Arquitectura del Sistema

El sistema está estructurado bajo un modelo de arquitectura de software desacoplado y orientado a microservicios/APIs en la nube, optimizando el consumo de recursos de cómputo y garantizando alta disponibilidad.

Flujo de Datos y Componentes Principales:
Cliente / Interfaz (Streamlit): El usuario carga una imagen desde la interfaz web. **Motor de Inferencia Local (TensorFlow/Keras):** Preprocesa la imagen (224x224 RGB) y realiza la clasificación con el modelo preentrenado MobileNetV2, retornando la clase y el porcentaje de confianza. **Orquestador de Prompt & Client Groq:** Toma la clase identificada y formula un prompt estructurado agronómico. **Servicio Cloud Groq API (LLM Llama 3.3):** Procesa el requerimiento y genera recomendaciones técnicas detalladas. **Renderizado Dinámico:** La interfaz despliega de forma unificada el diagnóstico visual, métricas de precisión y el reporte agronómico.

3. Servicios en la Nube y Tecnologías Utilizadas

Capa / Componente	Servicio / Tecnología	Propósito y Función en la Nube
Entorno de Entrenamiento	Google Colab (GPU Cloud)	Entrenamiento de la red CNN, data augmentation y exportación de artefactos (.keras y .json).
Control de Versiones	GitHub Repository	Alojamiento del código fuente, gestión de dependencias (requirements.txt) y CI/CD continuo.
Servicio de Despliegue	Streamlit Community Cloud	Alojamiento del servicio web interactivo, ejecución de runtime Python y gestión de secretos (API Keys).
Servicio IA Generativa	Groq Cloud API (Llama 3.3 70B)	Inferencia ultra-rápida en la nube para la generación de recomendaciones técnicas agronómicas.
Librerías Core	TensorFlow, Pillow, NumPy, Groq SDK	Manipulación de matrices de imágenes, ejecución del modelo fitosanitario y comunicación HTTP.

4. Flujo Detallado de Funcionamiento

PASO 1 Recepción y Preprocesamiento: La imagen se convierte a espacio de color RGB, se redimensiona a 224x224 píxeles y se normaliza dividiendo sus valores entre 255.0.

PASO 2 Inferencia Fitosanitaria: La matriz ingresa al modelo MobileNetV2. Se obtiene un vector de probabilidades Softmax para identificar la patología dominante y su grado de certeza.

PASO 3 Generación de Asistencia Agronómica: Se envía la patología como parámetro de entrada a la API de Groq utilizando el modelo llama-3.3-70b-versatile con instrucciones específicas de agronomía preventiva.

PASO 4 Despliegue de Resultados: Presentación clara en la aplicación web dividida en diagnóstico, confianza (%) y fichas desplegadas de tratamiento.

5. Conclusión y Valor del Enfoque Cloud

La integración de servicios en la nube democratiza el acceso a herramientas de precisión para agricultores y técnicos de campo. Al desacoplar el procesamiento pesado (entrenado previamente en Google Colab) y la inferencia del lenguaje (delegada a Groq Cloud), la aplicación ligera de Streamlit responde en segundos sin requerir hardware especializado en el dispositivo del cliente final.